



Modelos de Recuperación de Información (y evaluación)

Fecha entrega: 10/04/2024

Para la entrega del TP resuelto arme un único archivo comprimido (.tar.gz) y envíelo a través del siguiente formulario: <https://forms.gle/fcTfBySrfNNSordz9> el cual se encontrará habilitado hasta la fecha de entrega establecida.

Bibliografía sugerida: MIR [1] Capítulos 2 y 3, MAN [2] Capítulos 1,7,8,12.

1) Utilizando la colección provista por el equipo docente¹ cuya estructura es la siguiente:

- vocabulary.txt → [id_término, idf, término]
- documentVectors.txt → [id doc, lista(id_términos)]
- queries.txt → [id query, lista(id_términos)]
- relevants.txt → [id query, listarelevantes (id_doc)]
- informationNeeds.txt → [id_in, texto_libre]

a) Calcule los conjuntos de respuestas usando el modelo booleano y el modelo vectorial (asuma en todos los casos TF=1).

b) Compare los resultados contra los relevantes y trate de explicar las diferencias.

c) Usando las necesidades de información reescriba los 5 queries y repita la operación.

d) Indique si pudo mejorar la eficiencia a partir de las nuevas consultas.

2) Dados los siguientes documentos, arme la matriz término-documento (TD)²

- Doc1 = {El software libre ha tenido un papel fundamental en el crecimiento de Internet. Además, Internet ha favorecido la comunicación entre los desarrolladores de software.}
- Doc2 = {La mayor riqueza que tiene un país es la cultura, eso lo hace más libre.}
- Doc3 = {La producción de software es fundamental para nuestro país, como así también lo es la producción de tecnología de hardware y comunicación}
- Doc4 = {La cultura del software libre está en crecimiento. Es fundamental que nuestro país incorpore software libre en el estado.}

¹ Esta colección (<https://bit.ly/3cqhAg>) corresponde a un subconjunto de la "Cystic Fibrosis Collection". Los ejercicios fueron adaptados del curso del Prof. Berthier Ribeiro-Neto

²Nota: no tenga en cuenta los artículos, preposiciones y conectores

¿Qué documentos se recuperan en cada caso para las siguientes consultas booleanas? (Muestre mediante operaciones con conjuntos cómo se resuelven las consultas)

- a) (not software) or (pais and fundamental)
 - b) producción and (cultura or libre)
 - c) fundamental or libre or país
- 3) Utilizando los documentos del ejercicio anterior arme la matriz TD pero calculando w_{ij} como la frecuencia del i-ésimo término en el j-ésimo documento. Calcule el ranking para la siguientes consultas utilizando como métrica el producto escalar y luego repita con la métrica del coseno.
- a) software
 - b) país libre
 - c) producción software país
- 4) Rearme la matriz del ejercicio anterior pero calcule los pesos de acuerdo a $TF*IDF$. Repita todas las consultas (por ambas métricas). ¿Puede obtener alguna conclusión?
- 5) Utilizando Terrier³ indexe la colección Wiki-Small⁴. Tome 5 necesidades de información y, de forma manual, derive una consulta (query). Para cada una, pruebe la recuperación por los modelos basados en $TF*IDF$ y BM25. ¿Cómo se comportan los rankings? Calcule el coeficiente de correlación para los primeros 10, 25 y 50 resultados. ¿Qué conclusiones obtiene?
- 6) Escriba un pequeño programa que lea un directorio con documentos de texto y arme una estructura de datos en memoria para soportar la recuperación. Luego, debe permitir ingresar un query y devolver un ranking de los documentos relevantes utilizando el modelo vectorial. Se debe soportar la ponderación de los términos de la consulta. Implemente las versiones sugeridas en MIR [1].
- 7) Indexe la colección del ejercicio 5 con su software. Ejecute las consultas y compare los resultados con los obtenidos con Terrier. ¿Son consistentes?
- 8) Se requiere evaluar la performance en la recuperación de un sistema. Para una consulta $q1$, dicho sistema entregó la siguiente salida:

³ <http://www.terrier.org/>

⁴ <http://dg3rtljvitrie.cloudfront.net/wiki-small.tar.gz>



1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
R	N	N	R	R	N	N	N	N	R	N	N	N	R	N

Los documentos identificados como R son los relevantes, mientras que las N's corresponden a documentos no relevantes a $q1$. Suponga, además, que existen en el corpus otros 6 documentos relevantes a $q1$ que el sistema no recuperó. A partir de esta salida calcule las siguientes medidas:

- Recall y Precisión para cada posición j
- Precisión promedio
- Precisión al 50 % de Recall
- Precisión interpolada al 50 % de Recall
- Precisión-R

Finalmente, realice las gráficas interpolada y sin interpolar. Luego, interprete brevemente los resultados y brinde una explicación.

- Utilizando la colección de prueba CISI⁵ y Terrier se debe realizar la evaluación del sistema. Para ello, es necesario construir un índice con los documentos de la colección y luego ejecutar las consultas, las cuales deben armar a partir de los términos que considere de las necesidades de información. Los resultados deben ser comparados contra los juicios de relevancia de la colección utilizando el software trec_eval⁶. Realizar el análisis y escribir un reporte indicando los resultados obtenidos, junto con la gráfica de R-P en los 11 puntos standard. Realice dos experimentos: en el primero, no considere la frecuencia de los términos en el query mientras que en el segundo lo debe tener en cuenta
- Dadas las salidas de tres sistemas de recuperación de información para 3 consultas cualquiera⁷ y los juicios de relevancia creados por asesores humanos⁸ calcule para cada sistema:
 - La precisión media
 - La precisión media a intervalos de Recall de 20 %
 - P@5, P@10, P@20

⁵ http://ir.dcs.gla.ac.uk/resources/test_collections/cisi/

⁶ https://trec.nist.gov/trec_eval/

⁷ <http://www.labredes.unlu.edu.ar/sites/www.labredes.unlu.edu.ar/files/site/data/ri/Ejer-Evaluacion-OUTPUT.ods>

⁸ <http://www.labredes.unlu.edu.ar/sites/www.labredes.unlu.edu.ar/files/site/data/ri/Ejer-Evaluacion-JR.ods>



Luego, exponga un escenario posible y medidas complementarias para decidir qué sistema utilizar.

Bibliografía

- [1] Ricardo Baeza-Yates and Berthier Ribeiro-Neto. Modern Information Retrieval: The Concepts and Technology Behind Search. Addison-Wesley Publishing Company, USA, 2nd edition, 2008.
- [2] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. Introduction to Information Retrieval. Cambridge University Press, New York, NY, USA, 2008.